

# Audion Office OCR AI - руководство пользователя

Audion Office OCR AI превращает офисные документы, PDF, изображения и сканы в независимый `DocumentModel`, а затем сразу формирует выбранные офисные, архивные и машинные результаты. Markdown остаётся одним из экспортов для аудита и LLM, но не является центром системы.

## Запуск

```
launcher_gui.cmd
```

Обычная работа идёт через GUI. Проектные папки:

|            |                                        |
|------------|----------------------------------------|
| input\     | исходные документы                     |
| output\    | готовые пользовательские результаты    |
| config\    | настройки, промпты, API-ключи          |
| docs\      | документация проекта                   |
| docs\PDF\  | PDF-версии документации                |
| logs\      | журналы запусков                       |
| report\    | служебные отчёты                       |
| workspace\ | временные рабочие материалы и проверки |
| cache\     | OCR/preprocess cache                   |

Для CLI/FZF используйте `launcher_project.cmd` или `launcher_project_ru.cmd`. Они запускают тот же manifest/service-слой, что и GUI: OCR Brick, Workbench resolver и офисные сборщики не имеют отдельной CLI-копии backend. Канонический Workbench использует названия `Источник`, `Добавить файл...`, `Назначение`, `Сбросить`, `Удалить`, `Список`.

`<имя>.document` — внутренний канонический пакет OCR. Он сохраняет исходник, изображения страниц, OCR-кандидаты, координаты, таблицы, порядок чтения, confidence, результаты сверки и

ручные исправления. Полнота означает отсутствие потерь исходных данных, а не обещание абсолютной точности распознавания.

## Главное меню

### Офисный текст без OCR

Для DOCX/XLSX/PPTX/PDF/TXT/CSV/HTML, где текст уже можно извлечь без чтения пикселей.

### Локальный OCR

Бесплатный OCR на этой машине. Основной рекомендуемый движок - Tesseract. Surya оставлен как медленный optional-режим, когда жалко денег на API и есть время.

### Платный API OCR

OCR/vision-модели через Yandex, xAI, Mistral OCR 4, Gemini и OpenAI. Движок выбирается одной строкой компактных кнопок; выбранный движок определяет набор параметров ниже. Здесь же доступна управляемая проверка вторым проходом: для Mistral можно выбрать **Нет**,

**Tesseract**, **Yandex** или **Yandex + Tesseract**.

В **Локальном OCR** и **Платном API OCR** сразу под движком находится общий блок **Готовые файлы**. Рабочий дефолт — только **DOCX**. Две строки прямоугольных checkbox-чипов образуют ровную сетку 4×2:

- офисные форматы: **DOCX**, **XLSX**, **Searchable PDF**, **ODT**;
- форматы аудита и разработки: **Markdown**, **OCR JSON**, **HTML**, **Проверка**.

Форматы выбираются независимо и могут формироваться одновременно. Сетка лежит на отдельном затемнённом фоне; повторная подпись **Выходные форматы** не показывается. Нижний поясняющий блок сохранён. Полный ZIP-архив поддерживается backend для совместимости, но не показывается в основном OCR-интерфейсе. Каждый отмеченный результат сразу собирается из сохранённого **DocumentModel** без повторного OCR.

В секции **Результат** кнопки контракта **Текст + боксы** и **Раскладка** делят всю строку на две равные колонки. Контракт определяет полноту данных OCR, а не конечный офисный формат.

В блоке **Обслуживание** есть подтверждаемая кнопка **Очистить DocumentModel**. Она удаляет внутренние пакеты **\*.document**, **\*.document.json** и **\*.verification.json** из управляемых **output**, **report** и **workspace**, но сохраняет DOCX, XLSX, Markdown, PDF, изображения, исходные файлы и уже собранные full archive ZIP.

### Тест качества OCR

Проверка одной страницы перед массовым прогоном. Можно сравнить raw/clean и

локальные/API-движки.

#### Проверка реквизитов

Проверяет точные юридические и финансовые строки: номера контрактов, ИКЗ, даты, суммы и похожие поля. Инструмент не переписывает OCR самовольно, а пишет отчёт match/mismatch/uncertain.

#### Таблицы

Три операции раскрыты прямо в одном окне без вложенной навигации: извлечение координатных строк в XLSX, проверка Markdown-таблиц и сборка XLSX. Для линованных сканов основной OCR-backend дополнительно восстанавливает физическую сетку, проверяет число столбцов и сравнивает провайдеров внутри подтверждённых ячеек.

#### DEV Markdown PDF

Сборка dark/light PDF из Markdown через Chromium. По умолчанию выбран docs\PDF. Режим PDF рядом с MD создаёт одну подпапку PDF в каждой папке с Markdown, а Зеркало в Назначение формирует отдельное дерево через текущую папку Workbench.

#### Инструменты проекта

Установка и проверка окружения: Tesseract, Real-ESRGAN, Surya/Illama.cpp, модели API, Gemini Batch, smoke-тесты и статус проекта. Здесь же находится экспертная Пересборка старого Markdown в DOCX/PDF/PPTX/XLSX для архивного compatibility-процесса; это не основной OCR-путь. Здесь и в Локальный OCR показывается компактный аппаратный бейдж с рекомендацией по GPU/CPU-пути.

## OCR

---

### Локальный OCR

Выбирайте Tesseract, если нужен быстрый бесплатный OCR, координаты слов, проверка реквизитов или searchable-PDF/text-layer workflow.

Выбирайте Surya, если нужен аккуратный локальный разбор сложной страницы и время не критично. Surya optional и может быть тяжёлым по зависимостям.

### Платный API OCR

Yandex полезен для русского OCR с координатами и режимами page, table, markdown, handwritten и другими.

Для буквального OCR первым пробуйте xAI `4.20 fast` (`grok-4.20-non-reasoning-latest`). Режим `4.20 quality` (`grok-4.20-reasoning-latest`) медленнее и предназначен для сложных таблиц, фрагментированных и тяжёлых сканов. xAI вызывается обычным `non-streaming chat/completions`: это исключает зависимость от нестабильного `streaming`-маршрута. На временных HTTP/сетевых сбоях backend выполняет до четырёх попыток с задержкой, строго проверяет UTF-8 и сохраняет успешные страницы в возобновляемом кэше. Чекбокс **Проверка русского OCR** по умолчанию выключен; при включении reasoning-модель перепроверяет только подозрительные страницы, а слишком сильные правки отклоняются и исходный вариант остаётся в метаданных.

**Mistral OCR 4** сохраняет собственную структуру страницы и табличные attachments. Для тяжёлых русских таблиц включайте второй проход **Yandex**, **Tesseract** или их комбинацию: backend сверяет текст внутри подтверждённой геометрии ячеек, а неоднозначные расхождения оставляет для проверки.

**Gemini** и **OpenAI** доступны как дополнительные vision OCR варианты и для статистики качества. Для Gemini можно выбрать тариф **Standard** или **Flex**: Flex дешевле, но может дольше ждать свободную мощность. Для больших несрочных прогонов используйте **Gemini Batch OCR** в инструментах проекта: сначала собирается JSONL/manifest, затем job отправляется в Google отдельным переключателем, а готовый результат забирается через **Забрать Gemini Batch**.

Подробности по режимам Gemini и проверенному dry-run: `docs\GEMINI_BATCH_FLEX.md`.

## Gemini Standard, Flex и Batch

**Standard** - обычный интерактивный запрос. Это безопасный выбор для одной страницы, проверки качества и ручных экспериментов.

**Flex** - интерактивный запрос с `service_tier=flex`. Он дешевле, но может ждать свободную мощность заметно дольше. В GUI это поле **Gemini tier**; для Flex таймаут увеличен.

**Batch** - асинхронный режим для больших несрочных прогонов. **Gemini Batch OCR** по умолчанию только готовит `workspace\gemini_batch\...\requests.jsonl` и `manifest.json`; отправка в Google включается отдельным переключателем **Отправить в Google**. **Забрать Gemini Batch** проверяет job и скачивает Markdown.

Проверено на `input\Вопрос 239.pdf`, страницы `6-8`, **Raw**, **DPI 300**, `gemini-3.5-flash`, без отправки в Google: создано 3 JSONL-запроса с ключами `239_page_0006`, `239_page_0007`, `239_page_0008`.

## Очистка скана

---

В OCR-окнах секция **Препроцессинг** содержит одну строку профилей. Повторная подпись **Очистка скана** скрыта, а нижнее пояснение сохранено:

- **Авто** - рекомендуемый режим; настройки берутся под выбранный движок.
- **Без очистки** - отправить страницу как есть.
- **Тяжёлый скан** - сильнее убрать JPEG-шум, поднять контраст и резкость.
- **Цифры** - профиль для номеров, дат, сумм и реквизитов.
- **Ручной** - открыть старые подробные настройки в Advanced.

## Ключи API

---

Ключи хранятся в **config\**. Добавление и удаление ключей делается из GUI рядом с полем провайдера. Удаление ключа должно подтверждаться предупреждением. Не кладите реальные ключи в публичные архивы.

## Перед массовым прогоном

---

Сначала запускайте **Тест качества OCR** на одной странице. Для юридических документов дополнительно запускайте **Проверка реквизитов**. Затем выберите движок, профиль очистки и нужные готовые файлы. После OCR проверяйте DOCX/XLSX и отчёты в **report**; Markdown нужен только тогда, когда он выбран как отдельный аудит-формат.