

Audion Office OCR AI - руководство пользователя

Audion Office OCR AI превращает офисные документы, PDF, изображения и сканы в независимый **DocumentModel**, а затем сразу формирует выбранные офисные, архивные и машинные результаты. Markdown остаётся одним из экспортов для аудита и LLM, но не является центром системы.

Запуск

```
launcher_gui.cmd
```

Обычная работа идёт через GUI. Проектные папки:

input\	исходные документы
output\	готовые пользовательские результаты
config\	настройки, промпты, API-ключи
docs\	документация проекта
docs\PDF\	PDF-версии документации
logs\	журналы запусков
report\	служебные отчёты
workspace\	временные рабочие материалы и проверки
cache\	OCR/preprocess cache

Для CLI/FZF используйте **launcher_project.cmd** или **launcher_project_ru.cmd**. Они запускают тот же manifest/service-слой, что и GUI: OCR Brick, Workbench resolver и офисные сборщики не имеют отдельной CLI-копии backend. Канонический Workbench использует названия **Источник**, **Добавить файл...**, **Назначение**, **Сбросить**, **Удалить**, **Список**.

<имя>.document — внутренний канонический пакет OCR. Он сохраняет исходник, изображения страниц, OCR-кандидаты, координаты, таблицы, порядок чтения, confidence, результаты сверки и

ручные исправления. Полнота означает отсутствие потерь исходных данных, а не обещание абсолютной точности распознавания.

Главное меню

Офисный текст без OCR

Для DOCX/XLSX/PPTX/PDF/TXT/CSV/HTML, где текст уже можно извлечь без чтения пикселей.

Локальный OCR

Бесплатный OCR на этой машине. Основной рекомендуемый движок - Tesseract. Surya оставлен как медленный optional-режим, когда жалко денег на API и есть время.

Платный API OCR

OCR/vision-модели через Yandex, xAI, Mistral OCR 4, Gemini и OpenAI. Движок выбирается одной строкой компактных кнопок; выбранный движок определяет набор параметров ниже. Здесь же доступна управляемая проверка вторым проходом: для Mistral можно выбрать **Нет**, **Tesseract**, **Yandex** или **Yandex + Tesseract**.

В **Локальном OCR** и **Платном API OCR** сразу под движком находится общий блок **Готовые файлы**. Рабочий дефолт — только **DOCX**. Две строки прямоугольных checkbox-чипов образуют ровную сетку 4×2:

- офисные форматы: **DOCX**, **XLSX**, **Searchable PDF**, **ODT**;
- форматы аудита и разработки: **Markdown**, **OCR JSON**, **HTML**, **Проверка**.

Форматы выбираются независимо и могут формироваться одновременно. Сетка лежит на отдельном затемнённом фоне; повторная подпись **Выходные форматы** не показывается. Нижний поясняющий блок сохранён. Полный ZIP-архив поддерживается backend для совместимости, но не показывается в основном OCR-интерфейсе. Каждый отмеченный результат сразу собирается из сохранённого **DocumentModel** без повторного OCR.

В секции **Результат** кнопки контракта **Текст + боксы** и **Раскладка** делят всю строку на две равные колонки. Контракт определяет полноту данных OCR, а не конечный офисный формат.

В блоке **Обслуживание** есть подтверждаемая кнопка **Очистить DocumentModel**. Она удаляет внутренние пакеты ***.document**, ***.document.json** и ***.verification.json** из управляемых **output**, **report** и **workspace**, но сохраняет DOCX, XLSX, Markdown, PDF, изображения, исходные файлы и уже собранные full archive ZIP.

Тест качества OCR

Проверка одной страницы перед массовым прогоном. Можно сравнить raw/clean и

локальные/API-движки.

Проверка реквизитов

Проверяет точные юридические и финансовые строки: номера контрактов, ИКЗ, даты, суммы и похожие поля. Инструмент не переписывает OCR самовольно, а пишет отчёт match/mismatch/uncertain.

Таблицы

Три операции раскрыты прямо в одном окне без вложенной навигации: извлечение координатных строк в XLSX, проверка Markdown-таблиц и сборка XLSX. Для линованных сканов основной OCR-backend дополнительно восстанавливает физическую сетку, проверяет число столбцов и сравнивает провайдеров внутри подтверждённых ячеек.

DEV Markdown PDF

Сборка dark/light PDF из Markdown через Chromium. По умолчанию выбран `docs\PDF`. Режим

`PDF рядом с MD` создаёт одну подпапку `PDF` в каждой папке с Markdown, а `Зеркало в`

`Назначение` формирует отдельное дерево через текущую папку Workbench.

Инструменты проекта

Установка и проверка окружения: Tesseract, Real-ESRGAN, Surya/Illama.cpp, модели API, Gemini Batch, smoke-тесты и статус проекта. Здесь же находится экспертная `Пересборка старого`

`Markdown` в DOCX/PDF/PPTX/XLSX для архивного compatibility-процесса; это не основной OCR-путь. Здесь и в `Локальный OCR` показывается компактный аппаратный бейдж с рекомендацией по GPU/CPU-пути.

OCR

Локальный OCR

Выбирайте `Tesseract`, если нужен быстрый бесплатный OCR, координаты слов, проверка реквизитов или searchable-PDF/text-layer workflow.

Выбирайте `Surya`, если нужен аккуратный локальный разбор сложной страницы и время не критично. Surya optional и может быть тяжёлым по зависимостям.

Платный API OCR

`Yandex` полезен для русского OCR с координатами и режимами `page`, `table`, `markdown`, `handwritten` и другими.

Для буквального OCR первым пробуйте xAI **4.20 fast** (**grok-4.20-non-reasoning-latest**). Режим **4.20 quality** (**grok-4.20-reasoning-latest**) медленнее и предназначен для сложных таблиц, фрагментированных и тяжёлых сканов. xAI вызывается обычным non-streaming **chat/completions**: это исключает зависимость от нестабильного streaming-маршрута. На временных HTTP/сетевых сбоях backend выполняет до четырёх попыток с задержкой, строго проверяет UTF-8 и сохраняет успешные страницы в возобновляемом кэше. Чекбокс **Проверка русского OCR** по умолчанию выключен; при включении reasoning-модель перепроверяет только подозрительные страницы, а слишком сильные правки отклоняются и исходный вариант остаётся в метаданных.

Mistral OCR 4 сохраняет собственную структуру страницы и табличные attachments. Для тяжёлых русских таблиц включайте второй проход **Yandex**, **Tesseract** или их комбинацию: backend сверяет текст внутри подтверждённой геометрии ячеек, а неоднозначные расхождения оставляет для проверки.

Gemini и **OpenAI** доступны как дополнительные vision OCR варианты и для статистики качества. Для Gemini можно выбрать тариф **Standard** или **Flex**: Flex дешевле, но может дольше ждать свободную мощность. Для больших несрочных прогонов используйте **Gemini Batch OCR** в инструментах проекта: сначала собирается JSONL/manifest, затем job отправляется в Google отдельным переключателем, а готовый результат забирается через **Забрать Gemini Batch**.

Подробности по режимам Gemini и проверенному dry-run: **docs\GEMINI_BATCH_FLEX.md**.

Gemini Standard, Flex и Batch

Standard - обычный интерактивный запрос. Это безопасный выбор для одной страницы, проверки качества и ручных экспериментов.

Flex - интерактивный запрос с **service_tier=flex**. Он дешевле, но может ждать свободную мощность заметно дольше. В GUI это поле **Gemini tier**; для Flex таймаут увеличен.

Batch - асинхронный режим для больших несрочных прогонов. **Gemini Batch OCR** по умолчанию только готовит **workspace\gemini_batch\...\requests.jsonl** и **manifest.json**; отправка в Google включается отдельным переключателем **Отправить в Google**. **Забрать Gemini Batch** проверяет job и скачивает Markdown.

Проверено на **input\Вопрос 239.pdf**, страницы **6-8**, **Raw**, **DPI 300**, **gemini-3.5-flash**, без отправки в Google: создано 3 JSONL-запроса с ключами **239_page_0006**, **239_page_0007**, **239_page_0008**.

Очистка скана

В OCR-окнах секция **Преппроцессинг** содержит одну строку профилей. Повторная подпись **Очистка скана** скрыта, а нижнее пояснение сохранено:

- **Авто** - рекомендуемый режим; настройки берутся под выбранный движок.
- **Без очистки** - отправить страницу как есть.
- **Тяжёлый скан** - сильнее убрать JPEG-шум, поднять контраст и резкость.
- **Цифры** - профиль для номеров, дат, сумм и реквизитов.
- **Ручной** - открыть старые подробные настройки в Advanced.

Ключи API

Ключи хранятся в **config**. Добавление и удаление ключей делается из GUI рядом с полем провайдера. Удаление ключа должно подтверждаться предупреждением. Не кладите реальные ключи в публичные архивы.

Перед массовым прогоном

Сначала запускайте **Тест качества OCR** на одной странице. Для юридических документов дополнительно запускайте **Проверка реквизитов**. Затем выберите движок, профиль очистки и нужные готовые файлы. После OCR проверяйте DOCX/XLSX и отчёты в **report**; Markdown нужен только тогда, когда он выбран как отдельный аудит-формат.